

实习经历 EXPERIENCE

- Holistic AI Research Intern • London2026.06–2026.09
 - 参与并承担 LLM / Agent 红队与评测能力建设，将攻击生成、target execution、grader 与 FP/FN 分析串成可复现流程；重点判断攻击是否真实成功、判官是否误判。
 - 将既有红队流程迁移为更可控、可审计的 evaluation workflow 并接入实际平台；在 multi-turn attacker–target–judge 设置下区分 真实 breach / 模型拒答 / provider filter / judge error。
 - 使用人工/独立 gold labels 审计 grader 并分析系统性误判；相关可公开方法与实现已在个人项目 redteam-under-test 中独立重构。
- 华电集团 • 南京南自华盾数字技术有限公司 AI 技术实习生2025.08–2025.09
 - 参与电力行业大模型与企业知识系统，覆盖行业知识适配、RAG/问答链路测试与企业部署约束分析。

研究与论文 RESEARCH

- Routing Is Least Learnable Where It Is Most Valuable UCL MSc Dissertation2026Submitted: EMNLP 2026 Workshop REALM • NeurIPS 2026 Workshop VLM4RWD
 - 研究 Web Agent 的 DOM / Set-of-Marks / vision 与 phantom representations，构建 3 个模型族 × 6 种观测模式的预注册评测系统。
 - 发现 routing value–learnability gap：表征组合存在真实 oracle headroom，但 learned routing 在最有价值的场景反而最难可靠学习；将负结果与 failure analysis 作为主结论。
 - 工程系统约 117K LOC Python / 1,121 test functions，覆盖 VisualWebArena、Playwright、异构算力编排、结构化日志、自动恢复及 activation patching / linear probes。

精选项目 SELECTED SYSTEMS

- redteam-under-test Local-first LLM Red-Team Measurement Stack2026
 - 将 166 个 plugin 映射到本地生成机制，103 个经端到端验证后启用，11 个攻击技术重实现为本地 engine；攻击按目标领域动态实例化，而非重放固定 prompt bank。
 - 把 grader 本身纳入测量：对独立 gold labels 做 FP/FN 审计；公开实验 tuned judge 达 recall .712–.753 / precision .93–.98，同批 upstream rubric recall 为 .247。
 - 构建 zero-egress 本地路径、cockpit、Postgres 数据层与本地/云 executor，并显式区分 breach、refusal、provider filter 与 judge error。
- Agent Red-Team Lab Tool-Using Agent Security / MCP2026
 - 构建只读、离线的 MCP tool-call trace 安全分析器，检测 trust-boundary crossing、敏感数据外传、破坏性操作与 confused-deputy / authorization 缺失。
 - 构建 multi-step tool-attack replay 框架，围绕 replay budget / model-hop 成本优化攻击组合；公开竞赛版本最佳分 72.72。

教育背景 EDUCATION

- University College London (UCL) MSc Artificial Intelligence for Sustainable Development • Computer Science2025.09–2026.09
- 西安交通大学 工学学士 • 自动化2021.09–2025.07

技能 SKILLS

- Evaluation / Research: LLM & Agent Evaluation • Benchmark Design • Red Teaming • Judge/Grader Evaluation • Failure Analysis • Bootstrap / Paired Testing
- Agents / Models: Web & Computer-Use Agents • VisualWebArena • MCP • Tool Use • PyTorch • Hugging Face • LoRA/SFT • GRPO/RLVR
- Engineering: Python • TypeScript/JavaScript • SQL/Postgres • Playwright • Docker • GitHub Actions • Linux • AWS/SST • Next.js/TanStack • SGE/HPC